

PEC 2 - Anàlisi de dades Òmiques

Alejandro Sendín Emiliano

2026-05-11

Contents

1	Introducció i objectius	1
2	Importació i descripció de les dades	1
3	Subconjunt de dades analitzat	2
4	Anàlisi exploratori i control de qualitat	3
5	Preprocessat de les dades	6
6	Model i disseny experimental	7
7	Expressió diferencial	8
8	Anàlisi de significació biològica (ORA)	10
9	Anàlisi de sobrerepresentació (ORA)	11
10	Discussió i conclusions	12
11	Apèndix 1: Pregunta bonus opcional nº3 - ORA amb els gens infraexpressats	13
12	Apèndix 2: Codi R utilitzat	14

1 Introducció i objectius

Aquesta pràctica consisteix en realitzar una **anàlisi d'expressió diferencial** completa a partir d'unes dades d'RNA-seq de l'estudi públic **GSE50760**. En aquesta ocasió les dades ja venen donades per l'arxiu *PEC2_GSE50760_colorectal_SE.Rda*.

Els objectius seran doncs:

- Processar un objecte SummarizedExperiment
- Realitzar una primera anàlisi exploratoria
- Filtrar i normalitzar les dades
- Definir el disseny experimental: construir la matriu de disseny
- Analitzar l'expressió diferencial
- Analitzar l'enriquiment i la significació biològica

2 Importació i descripció de les dades

En primer lloc importem les dades per realitzar la pràctica:

```
load("PEC2_GSE50760_colorectal_SE.Rda")
```

Com s'ha indicat abans, aquestes dades provenen de l'estudi GSE50760 de GEO. S'han obtingut mostres de teixit sa del colon, del tumor i del teixit metastàtic del fetge en cadascun dels 18 pacients de l'estudi. Segons les dades del repositori de GEO, la preparació i seqüenciació es va fer mitjançant instrumental de l'empresa Illumina, mentre que l'amplificació dels fragments es va realitzar mitjançant PCR.

Es visualitzen les dades:

```
## [1] "SummarizedExperiment"
## [1] 39376      54
## [1] "counts" "logCPM" "TPM"      "FPKM"
```

Veiem que les dades es troben integrades en un objecte de tipus **SummarizedExperiment** (SE) que conté la informació de:

- **assays**: Conté els diferents assajos realitzats entre les files (els diferents gens) i les columnes (les mostres de l'experiment). En aquest cas s'han recollit 4 variables diferents que conformen els 4 assajos.
 - counts: recompte de gens per mostra.
 - logCPM: recompte per milió a escala logarítmica.
 - TPM: trànscripats per milió.
 - FPKM: fragments per kilobase i per milió.
- **rowData**: les files són els diferents gens i cada columna una variable tècnica de cada gen. Hi ha un total de 8 variables que aporten informació sobre cada gen.
- **colData**: les files són les diferents mostres i cada columna una variable biològica descriptiva de les mostres. N'hi ha un total de 10 variables que descriuen les mostres.
- **metadata**: conté informació addicional sobre l'experiment. En aquest cas són 12 ítems informatius.

En concret, SE conté 39376 gens i 54 mostres. Com s'ha vist, aquestes conformen un total de 4 assajos diferents. Cada mostra ve caracteritzada per les variables biològiques: `geo_accession`, `sample_title`, `source_name`, `characteristics_1`, `characteristics_2`, `sample_name`, `patient_id`, `condition`, `sample_type`, `pair_group`. Per altra banda els gens es caracteritzen per les variables: `gene_id`, `gene_symbol`, `description`, `gene_type`, `chromosome`, `map_location`, `entrez_id`, `has_entrez`.

El disseny de l'estudi es basa en l'estructura següent:

```
##           condition
## patient_id normal primary_tumor liver_metastasis
##   AMC_10      1           1           1
##   AMC_12      1           1           1
##   AMC_13      1           1           1
##   AMC_17      1           1           1
##   AMC_18      1           1           1
##   AMC_19      1           1           1
```

Es mostren els primers 6 pacients, però hi ha un total de 18, cadascun amb 3 mostres analitzades (*normal*, *primary_tumor* i *liver_metastasis*).

3 Subconjunt de dades analitzat

Per individualitzar la pràctica, es selecciona una mostra per estudiant, en el meu cas s'obté `se_sub`.

```
# Faré servir les 4 últimes xifres del meu DNI
myseed <- sum(utf8ToInt("2426"))
set.seed(myseed)
```

```

patients <- unique(se$patient_id)
selected_patients <- sample(patients, 10)

se_sub <- se[, se$patient_id %in% selected_patients]
se_sub

## class: SummarizedExperiment
## dim: 39376 30
## metadata(12): geo_accession title ... creation_date input_files
## assays(4): counts logCPM TPM FPKM
## rownames(39376): 100287102 653635 ... 4576 4571
## rowData names(8): gene_id gene_symbol ... entrez_id has_entrez
## colnames(30): primary_colorectal_cancer_AMC_2-1
##   primary_colorectal_cancer_AMC_3-1 ... metastasized_cancer_AMC_21-3
##   metastasized_cancer_AMC_23-3
## colData names(10): geo_accession sample_title ... sample_type
##   pair_group

```

I es confirma l'estructura de l'estudi es manté:

```


##           condition
## patient_id normal primary_tumor liver_metastasis
##   AMC_10      1           1           1
##   AMC_13      1           1           1
##   AMC_17      1           1           1
##   AMC_2       1           1           1
##   AMC_20      1           1           1
##   AMC_21      1           1           1
##   AMC_23      1           1           1
##   AMC_3       1           1           1
##   AMC_6       1           1           1
##   AMC_7       1           1           1

```


Tal i com es veu a la taula, els pacients seleccionats són: **10, 13, 17, 2, 20, 21, 23, 3, 6 i 7** i tots ells tenen els 3 tipus de teixit disponible. Això s'ha visualitzat “a mà” però si el llistat hagués sigut molt més complex s'hauria d'haver fet servir un bucle que pentinés tot el subconjunt.

4 Anàlisi exploratori i control de qualitat

Per explorar la distribució de les dades primer fem un *boxplot*:




Aparentment no s'aprecia cap problema en quant als valors de **logCPM**. Ara es pot fer un **dendrograma** per avaluar els grups en que es classifiquen:



A priori, tot i que hi hagi algunes excepcions, els grups es distribueixen segons el tipus de teixit de forma evident.

Finalment es realitza un anàlisi *PCA* distingint els valors segons el tipus de teixit de la mostra, ja que és el que esperem que expliqui la variabilitat:

PCA de les mostres segons tipus teixit




Segons el gràfic obtingut el que es pot apreciar és que efectivament sembla que hi ha una agrupació de les mostres segons el tipus de teixit. De fet, els valors del teixit normal apareixen sobretot al centre del gràfic mentre que els del tumor principal i els del teixit metastàtic es troben situats cap a la part positiva de la primera component. Per tant, tot i que amb el boxplot es podria dir que les mostres són comparables entre si, sembla que s'hauria de tenir en compte aquesta organització interna.

Per altra banda, la variabilitat explicada per les dues components en el PCA no és massa gran però tampoc implica que l'anàlisi sigui erroni, simplement no hi ha tanta correlació com la que s'ha vist en altres exercicis.

Finalment si que és destacable el punt situat a la part més negativa tant de la component 1 com la 2 corresponent al teixit normal. Aquesta dada és un "outlier" i probablement caldria revisar les dades relacionades amb aquesta mostra per valorar la seva implicació a l'estudi.

Aprofitant aquesta dada, es realitza el mateix gràfic PCA però mostrant els identificadors de pacient, per un costat per veure quina dada és i, per l'altre, per veure si hi ha efecte pacient:

PCA de les mostres segons el pacient



Simplement canviant la variable definida *condition* per aquella amb la que volem ilustrar els punts i afegint etiquetes s'obté el gràfic PCA per pacient, en el que veiem com l'outlier pertany a la mostra de **teixit normal del pacient n^o3**. No s'aprecia cap agrupació específica per pacient.

Per acabar, en aquest estudi sembla que no s'ha indicat el número de lot, de forma que no és possible indagar sobre si afecta a l'agrupació de mostres obtinguda. Segurament no seria així ja que s'ha vist que l'agrupació prové del tipus de teixit, que ja es coherent, però si qualsevol altra variable (com el lot o el tipus de pacient) coincidís amb aquesta agrupació, probablement hi hauria un error en el procés d'obtenció de les mostres.

5 Preprocessat de les dades

Per filtrar les dades es fa servir la funció `cpm()` del paquet `edgeR`:

```
cpm_data <- cpm(assay(se_sub, "counts"))

# s'obtenen els gens amb CPM > 1 en >= 5 mostres
keep_genes <- rowSums(cpm_data > 1) >= 5
se_sub_filt <- se_sub[keep_genes, ]

# es visualitza el canvi de dimensió
dim(se_sub)
```

```
## [1] 39376    30
```

```
dim(se_sub_filt)
```

```
## [1] 18561    30
```

Per falta d'experiència, s'ha cregut convenient el criteri de filtratge establert a l'enunciat.

Com es pot veure, aquest criteri ha reduït el tamany de les dades **de 39376 gens a 18561**, és a dir, aproximadament la meitat no compleixen el criteri establert.

Ara a partir d'aquest subconjunt filtrat es realitza una normalització, de nou, fent servir `edgeR`.

```
# es crea l'objecte de classe S4 DGEList
dgeObj <- DGEList(counts = (assay(se_sub_filt, "counts")))

# es calculen els factors de normalització i s'inclouen a la llista de l'objecte DGE
dgeObj_norm <- calcNormFactors(dgeObj, method = "TMM")
```

El criteri per fer servir `edgeR` és degut a que és senzill d'aplicar i encaixa amb les dades de recompte de RNA-seq que tenim. Aporta els factors de normalització necessaris per establir un tamany de llibreria adequat segons el nivell de variabilitat dels gens.

A partir d'aquí es podria considerar repetir l'exploració de les dades i veure si hi ha cap canvi.

6 Model i disseny experimental

Tenint ja el subconjunt `se_sub` filtrat (`se_sub_filt`), s'obtenen les dades només de les mostres *normal* i *primary_tumor*, creant un nou subconjunt filtrat anomenat `se_pn`:

```
se_pn <- se_sub_filt[, colData(se_sub_filt)$condition %in% c("primary_tumor", "normal")]
table(colData(se_pn)$condition)
```

```
##
##          normal      primary_tumor liver_metastasis
##             10             10             0
```

```
table(colData(se_pn)$patient_id)
```

```
##
## AMC_10 AMC_13 AMC_17  AMC_2 AMC_20 AMC_21 AMC_23  AMC_3  AMC_6  AMC_7
##      2      2      2      2      2      2      2      2      2      2
```

Al veure que encara es contempla el nivell *liver_metastasis*, s'elimina. També es canvia la variable *patient_id* a *factor*

```
# s'elimina la categoria liver_metastasis
colData(se_pn)$condition <- droplevels(colData(se_pn)$condition)

# es converteix patient_id a factor
colData(se_pn)$patient_id <- factor(colData(se_pn)$patient_id)

tab_pairs <- table(patient_id = colData(se_pn)$patient_id, condition = colData(se_pn)$condition)
tab_pairs
```

```
##          condition
## patient_id normal primary_tumor
##   AMC_10      1          1
##   AMC_13      1          1
##   AMC_17      1          1
##   AMC_2       1          1
##   AMC_20      1          1
##   AMC_21      1          1
##   AMC_23      1          1
##   AMC_3       1          1
##   AMC_6       1          1
##   AMC_7       1          1
```

Els pacients seleccionats i amb les dues mostres són: **10, 13, 17, 2, 20, 21, 23, 3, 6 i 7**. És important

que el subconjunt contingui només pacients amb les dues mostres a comparar. La idea és avaluar l'expressió de gens en un teixit sa i malalt, de manera que fer aquesta comparació en un mateix subjecte és molt més significatiu que comparar totes les mostres entre si, ja que llavors s'inclou un biaix innecessari corresponent a la variabilitat genètica de la població. En altres paraules, s'entén que l'expressió gènica pot tenir certa variabilitat entre pacients, però serà la que és si es comparen mostres en cada pacient.

S'estableix la referència per a la matriu de disseny, en el cas d'estudi *normal* és la condició principal.

```
colData(se_pn)$condition <- relever(colData(se_pn)$condition, ref = "normal")
```

Per últim es recalculen els **factors de normalització TMM** necessaris per posteriorment fer l'anàlisi:

```
dge_pn <- DGEList(counts = assay(se_pn, "counts"))
dge_pn <- calcNormFactors(dge_pn, method = "TMM")
```

I es crea la **matriu de disseny**:

```
design <- model.matrix(~ patient_id + condition, data = as.data.frame(colData(se_pn)))
```

patient_id a més de representar la identificació de cada pacient, és la forma que hi ha de restringir l'anàlisi per a que les mostres a comparar ho facin en el si del mateix pacient i es pugui determinar diferències en l'expressió derivades només del propi teixit i no de la persona de la que provenen les mostres.

7 Expressió diferencial

En primer lloc es crea l'objecte *voom*, s'ajusta el **model lineal** amb la matriu de disseny i s'aplica la regularització de l'**estimador de l'error** amb *eBayes*.

```
voomObj <- voom(dge_pn, design)
fit <- lmFit(voomObj, design)
fit <- eBayes(fit)
```

Els resultats es mostren en la següent taula, on podem obtenir els *valors p* i el *logFC*, entre d'altres variables:

```
##          logFC AveExpr      t      P.Value    adj.P.Val      B
## 1001    5.639388 3.147784 21.60705 2.049546e-11 3.804162e-07 15.74509
## 128239 2.470290 4.689583 18.44793 1.447254e-10 1.343124e-06 14.69966
## 2118    5.092345 3.553312 16.51103 5.636717e-10 3.291971e-06 13.18926
## 113130 2.026275 3.907076 15.96110 8.517642e-10 3.291971e-06 12.98419
## 990     2.150774 3.876286 15.54152 1.177447e-09 3.291971e-06 12.67039
## 29128   2.354569 3.890189 15.36021 1.357625e-09 3.291971e-06 12.53137
## [1] 18561      6
```

Els **criteris** per realitzar l'anàlisi d'expressió diferencial són:

- **FDR < 0.05**: Implica conservar només els gens amb un p-valor ajustat (adj.P.val) inferior a 0.05.
- **|log2FC| > 2**: Implica conservar els gens amb un canvi en la expressió gènica en les condicions donades (logFC) superior a 2 ja siguin sobreexpressats o infraexpressats.

A continuació s'obté el llistat dels principals gens diferencialment expressats i la seva dimensió i s'ordena per *FDR* i per *|log2FC|*:

```
##          logFC AveExpr      t      P.Value    adj.P.Val      B
## 1001    5.639388 3.1477836 21.60705 2.049546e-11 3.804162e-07 15.74509
## 128239 2.470290 4.6895835 18.44793 1.447254e-10 1.343124e-06 14.69966
## 1469    7.052897 0.8228807 15.16055 1.590889e-09 3.291971e-06 11.31712
## 144501 6.667875 1.0192186 15.01331 1.790396e-09 3.291971e-06 11.23328
## 3651    5.147715 1.6120269 14.67941 2.349669e-09 3.291971e-06 11.51908
```



```
## 2118 5.092345 3.5533115 16.51103 5.636717e-10 3.291971e-06 13.18926
```

```
## [1] 1106 6
```

Ara es poden etiquetar aquests gens en **sobreexpressats** o **infraexpressats** segons si $\log_2FC$ és superior a 2 o inferior a -2.

```
res_DE$DE[res_DE$adj.P.Val < 0.05 & res_DE$logFC > 2] <- "Sobreexpressat"
res_DE$DE[res_DE$adj.P.Val < 0.05 & res_DE$logFC < -2] <- "Infraexpressat"
res_de_SE <- res_DE[res_DE$DE == "Sobreexpressat", ]
res_de_IE <- res_DE[res_DE$DE == "Infraexpressat", ]
```


En total, hi ha 1106 gens diferencialment expressats. Dels quals 497 estan sobreexpressats i 609 estan infraexpressats.

Els 10 gens més rellevants per ordre de significància estadística s'indiquen a continuació:

	gene_symbol	logFC	adj.P.Val	DE
1001	CDH3	5.639388	4.0e-07	Sobreexpressat
128239	IQGAP3	2.470290	1.3e-06	Sobreexpressat
1469	CST1	7.052897	3.3e-06	Sobreexpressat
144501	KRT80	6.667875	3.3e-06	Sobreexpressat
3651	PDX1	5.147715	3.3e-06	Sobreexpressat
2118	ETV4	5.092345	3.3e-06	Sobreexpressat
100507056	CCAT1	4.339885	3.3e-06	Sobreexpressat
54443	ANLN	2.759097	3.3e-06	Sobreexpressat
9603	NFE2L3	2.634797	3.3e-06	Sobreexpressat
3043	HBB	-2.535269	3.3e-06	Infraexpressat

Per últim es representa la diferenciació gènica amb un volcano plot:

Volcano plot



El número de gens diferencialment expressats constitueix aproximadament una 18^a part de la totalitat, tot i això, la immensa majoria compleix el criteri del FDR establert. Tot i que més o menys tenim la mateixa quantitat de sobreexpressats i infraexpressats, en la llista dels 10 que s'ha triat els 9 primers gens es troben sobreexpressats. Tenint en compte que els nivells de significància són tan bons, potser s'hauria de revisar el criteri i ordenar per nivell d'expressió del gen.

8 Anàlisi de significació biològica (ORA)

Ara es té el conjunt de dades `res_DE` que engloba tots els gens diferencialment expressats amb la seva notació `gene_symbol` que s'ha triat per ser més descriptiva.

Però cal revisar si aquests gens tenen identificador **Entrez**:

```
res_DE$entrez <- rowData(se_pn)[rownames(res_DE), "entrez_id"]
sum(is.na(res_DE$entrez_id))
```

```
## [1] 0
```

```
sum(is.na(res_DE$gene_symbol))
```

```
## [1] 0
```

Sembla que tots els gens tenen *identificador Entrez* així com *gene_symbol*. No ha calgut eliminar cap gen.

9 Anàlisi de sobreexpressió (ORA)

A continuació es realitza l'anàlisi de sobreexpressió. Es vol saber si hi ha processos biològics més abundants en el teixit de tumor primari que en el teixit normal. Per fer-ho, els gens sobreexpressats estan relacionats amb tasques biològiques, de manera que es pot avaluar la proporció d'aquestes tasques en els gens sobreexpressats en relació amb la proporció que hi ha en general i mirar el nivell de significació de la diferència.

Primer s'obtenen només els gens sobreexpressats del total `res_DE` en forma de vector per l'ORA:

```
res_de_SE <- res_DE[res_DE$DE == "Sobreexpressat", ]
res_entrez <- res_de_SE$entrez
```

Ara s'obtenen els identificadors entrez del total de gens amb els que s'ha iniciat l'estudi de diferenciació. També s'inclou la columna `gene_symbol` per si de cas:

```
# s'afegeix la columna entrez a res
res$entrez <- rowData(se_pn)[rownames(res), "entrez_id"]
res$gene_symbol <- rowData(se_pn)[rownames(res), "gene_symbol"]
sum(is.na(res_DE$entrez_id))
```

```
## [1] 0
```

```
sum(is.na(res_DE$gene_symbol))
```

```
## [1] 0
```

```
univers_entrez <- res$entrez
length(univers_entrez)
```

```
## [1] 18561
```

Ara es té `res_entrez` que és el vector amb els identificadors Entrez del gens sobreexpressats i `univers_entrez` que és el vector Entrez amb la totalitat de gens (els 18 mil).

Es procedeix a aplicar `enrichGO` i fer l'anàlisi d'enriquiment:


```
ego <- enrichGO(gene = res_entrez,
  universe = univers_entrez,
  keyType = "ENTREZID",
  OrgDb = org.Hs.eg.db,
  ont = "BP",
  pAdjustMethod = "BH",
  pvalueCutoff = 0.05,
  qvalueCutoff = 0.05, readable = TRUE)
```

S'han inclòs 497 gens sobreexpressats en l'anàlisi ORA, dels quals un total de 186 són els termes significatius de l'estudi. A continuació s'indica una taula resum:

Description	GeneRatio	p.adjust	Count
extracellular matrix organization	29/355	1.0e-07	29
extracellular structure organization	29/355	1.0e-07	29
antimicrobial humoral immune response mediated by antimicrobial peptide	16/355	1.0e-07	16
external encapsulating structure organization	29/355	1.0e-07	29
morphogenesis of an epithelium	37/355	2.0e-07	37
antimicrobial humoral response	18/355	2.0e-07	18
skin development	25/355	6.0e-07	25
epidermis development	27/355	1.0e-06	27
humoral immune response	23/355	1.4e-06	23

Description	GeneRatio	p.adjust	Count
keratinization	9/355	1.7e-06	9

A continuació es mostra un *dotplot* resum:



Els processos que destaquen en el teixit tumoral respecte el normal són processos que biològicament tenen sentit. Les cèl·lules del tumor, a trets generals, destaquen per la seva capacitat de reproduir-se adaptant-se a l'entorn que les envolta o alterant-lo. Per aquest motiu és coherent que els processos que es mostren en la taula i en el gràfic siguin tant rellevants en aquest estudi.

10 Discussió i conclusions

Les dades que s'han obtingut han sigut molt bones de cara a la realització de l'estudi. L'exploració de les dades ha sigut positiva, no s'ha evidenciat cap possible error d'agrupació o biaix. Només s'ha obtingut un outlier en l'anàlisi de PCA en la mostra normal del pacient n^o3 que no s'ha arribat a descartar. El filtratge i normalització del conjunt d'estudi també ha mostrat resultats esperables sense cap element a destacar. El disseny de l'estudi i el contrast escollit és el que es recomana a la metadata de les dades el qual tampoc ha generat cap mena de problema. Així doncs, considero que la preparació de les dades ha sigut la estàndar però ha ajudat molt el fet de treballar amb un estudi real i fàcilment interpretable.


En quant a les anàlisis dutes a terme, és interessant veure com de complex és en realitat l'entorn genètic. En el cas d'aquesta pràctica per exemple, l'expressió de gens no només canvia molt segons el teixit, si no que el canvi ve per una quantitat molt elevada de gens, és a dir, no és que hi hagi desenes de gens que s'expressin en un teixit de còlon sa i no ho facin de la mateixa manera en cèl·lules de còlon tumoral, és que són centenars, cosa que m'ha sorprès, tot i indicar uns criteris de FDR i FC contundents. De cara doncs a avaluar la rellevància, la quantitat de gens és força elevada i tots sembla que tinguin un paper igual d'important en distingir un teixit d'un altre.

Dels gens sobreexpressats en una proporció significativament més alta en el teixit tumoral, no sorprèn veure que estan involucrats en tasques relatives a l'entorn extracel·lular com ara l'organització i la formació d'elements. Si més no, són processos força genèrics que entenc que serveixen com a etiqueta general. El paper concret d'aquests gens és difícil de saber, però sembla interessant veure com en general les funcions més destacables són les del control de l'ambient extracel·lular de la cèlula tumoral. Hi ha altres processos immunològics que també s'indiquen i, de nou, tot i que encaixen amb les idees d'inflamació, infiltració i alteracions de la microbiota, es tracta de conceptes molt generals.

11 Apèndix 1: Pregunta bonus opcional nº3 - ORA amb els gens infraexpressats

A continuació es replica el mateix codi anteriorment descrit per fer un ORA amb els gens infraexpressats i avaluar els resultats:

Description	GeneRatio	p.adjust	Count
immunoglobulin mediated immune response	39/462	0.00e+00	39
B cell mediated immunity	39/462	0.00e+00	39
leukocyte mediated immunity	49/462	0.00e+00	49
lymphocyte mediated immunity	42/462	0.00e+00	42
adaptive immune response based on recombination of Ig dom immune receptors	42/462	0.00e+00	42
sodium ion transmembrane transport	21/462	3.10e-06	21
chloride transport	16/462	1.44e-05	16
flavonoid metabolic process	7/462	2.09e-05	7
sodium ion transport	23/462	2.51e-05	23
regulation of membrane potential	32/462	3.44e-05	32



El que s'obté és realment interessant. A diferència de l'ORA amb els gens sobreexpressats, on es podia veure un augment dels processos relacionats amb l'estructura extracel·lular de la cèl·lula tumoral, aquí es pot veure que en general la infraexpressió es dona en processos immunològics com ara la immunitat mediada per leucòcits i limfòcits o (i això és molt interessant tenint en compte l'auge de la immunoteràpia) la recombinació de receptors de la família Ig com a resposta adaptativa. És a dir, els processos poc presents en el teixit tumoral són aquells que precisament el podrien combatre, cosa que és coherent i té sentit en el context de les cèl·lules tumorals.

12 Apèndix 2: Codi R utilitzat

```
load("PEC2_GSE50760_colorectal_SE.Rda")

class(se)[1]
dim(se)
assayNames(se)

head(table(patient_id = colData(se)$patient_id, condition = colData(se)$condition))

myseed <- sum(utf8ToInt("2426"))
set.seed(myseed)

patients <- unique(se$patient_id)
```

```

selected_patients <- sample(patients, 10)

se_sub <- se[, se$patient_id %in% selected_patients]
se_sub

table(patient_id = colData(se_sub)$patient_id, condition = colData(se_sub)$condition)

logcpmdata <- assay(se_sub, "logCPM")
mostres <- colnames(se_sub)

boxplot(logcpmdata, las = 2, outline = FALSE, main = "Distribució logCPM per mostra",
        names = mostres, ylab = "logCPM")
abline(h=median(logcpmdata), col="blue")

clust.euclid.average <- hclust(dist(t(logcpmdata)), method = "average")
plot(clust.euclid.average, labels = mostres,
     main = "Dendrograma de logCPM (se_sub)", cex = 0.6, hang = -1)

condition <- as.factor(colData(se_sub)$condition)
colors <- as.numeric(condition)

pca <- prcomp(t(logcpmdata), center = TRUE, scale. = TRUE)
varexp <- round(100*pca$sdev^2/sum(pca$sdev^2), 1)

plot(pca$x[, 1], pca$x[, 2], col = colors, pch = 16, cex = 1.2,
     xlab = paste0("PC1 (", varexp[1], "%)"),
     ylab = paste0("PC2 (", varexp[2], "%)"),
     main = "PCA de les mostres segons tipus teixit"
)

legend("topleft", legend = levels(condition),
     col = seq_along(levels(condition)),
     pch = 16, cex = 0.8, title = "Condition"
)

condition <- as.factor(colData(se_sub)$patient_id)
colors <- as.numeric(condition)

pca <- prcomp(t(logcpmdata), center = TRUE, scale. = TRUE)
varexp <- round(100*pca$sdev^2/sum(pca$sdev^2), 1)

plot(pca$x[, 1], pca$x[, 2], col = colors, pch = 16, cex = 1.2,
     xlab = paste0("PC1 (", varexp[1], "%)"),
     ylab = paste0("PC2 (", varexp[2], "%)"),
     main = "PCA de les mostres segons el pacient"
)

text(pca$x[, 1], pca$x[, 2], labels = condition, cex = 0.5,
     pos = 3, offset = 0.3)

legend("topleft", legend = levels(condition),
     col = seq_along(levels(condition)),
     pch = 16, cex = 0.5, title = "Condition"
)

```

```

)

cpm_data <- cpm(assay(se_sub, "counts"))

keep_genes <- rowSums(cpm_data > 1) >= 5
se_sub_filt <- se_sub[keep_genes, ]

dim(se_sub)
dim(se_sub_filt)

dgeObj <- DGEList(counts = (assay(se_sub_filt, "counts")))

dgeObj_norm <- calcNormFactors(dgeObj, method = "TMM")

se_pn <- se_sub_filt[, colData(se_sub_filt)$condition %in% c("primary_tumor", "normal")]
table(colData(se_pn)$condition)
table(colData(se_pn)$patient_id)

colData(se_pn)$condition <- droplevels(colData(se_pn)$condition)

colData(se_pn)$patient_id <- factor(colData(se_pn)$patient_id)

tab_pairs <- table(patient_id = colData(se_pn)$patient_id,
                   condition = colData(se_pn)$condition)
tab_pairs

colData(se_pn)$condition <- relevel(colData(se_pn)$condition, ref = "normal")

dge_pn <- DGEList(counts = assay(se_pn, "counts"))
dge_pn <- calcNormFactors(dge_pn, method = "TMM")

design <- model.matrix(~ patient_id + condition, data = as.data.frame(colData(se_pn)))

voomObj <- voom(dge_pn, design)
fit <- lmFit(voomObj, design)
fit <- eBayes(fit)

res <- topTable(fit, coef = "conditionprimary_tumor", number = Inf)
head(res)
dim(res)

res_DE <- res[res$adj.P.Val < 0.05 & abs(res$logFC) > 2, ]
res_DE <- res_DE[order(res_DE$adj.P.Val, -abs(res_DE$logFC)), ]
head(res_DE)
dim(res_DE)

res_DE$DE[res_DE$adj.P.Val < 0.05 & res_DE$logFC > 2] <- "Sobreexpressat"
res_DE$DE[res_DE$adj.P.Val < 0.05 & res_DE$logFC < -2] <- "Infraexpressat"
res_de_SE <- res_DE[res_DE$DE == "Sobreexpressat", ]
res_de_IE <- res_DE[res_DE$DE == "Infraexpressat", ]

res_DE$gene_symbol <- rowData(se_pn)[rownames(res_DE), "gene_symbol"]
top10 <- head(res_DE, 10)

```



```

top10 <- top10[, c("gene_symbol", "logFC", "adj.P.Val", "DE")]
knitr::kable(top10)

# primer afegim la columna DE a la taula de resultats inicial
res$DE <- "No_dif"
res$DE[res$adj.P.Val < 0.05 & res$logFC > 2] <- "Sobreexpressat"
res$DE[res$adj.P.Val < 0.05 & res$logFC < -2] <- "Infraexpressat"

plot(res$logFC, -log10(res$adj.P.Val), pch = 16, cex = 0.5,
     col = ifelse(res$DE == "Sobreexpressat", "coral3",
                  ifelse(res$DE == "Infraexpressat", "chartreuse2", "grey")),
     xlab = "log2 Fold Change", ylab = "-log10(FDR)", main = "Volcano plot")

abline(v = c(-2, 2), lty = 2)
abline(h = -log10(0.05), lty = 2)

legend("topright", legend = c("No_dif", "Sobreexpressat", "Infraexpressat"),
     col = c("grey", "coral3", "chartreuse2"), pch = 16, cex = 0.8)

res_DE$entrez <- rowData(se_pn)[rownames(res_DE), "entrez_id"]
sum(is.na(res_DE$entrez_id))
sum(is.na(res_DE$gene_symbol))

res_de_SE <- res_DE[res_DE$DE == "Sobreexpressat", ]
res_entrez <- res_de_SE$entrez

res$entrez <- rowData(se_pn)[rownames(res), "entrez_id"]
res$gene_symbol <- rowData(se_pn)[rownames(res), "gene_symbol"]
sum(is.na(res_DE$entrez_id))
sum(is.na(res_DE$gene_symbol))
univers_entrez <- res$entrez
length(univers_entrez)

ego <- enrichGO(gene = res_entrez,
               universe = univers_entrez,
               keyType = "ENTREZID",
               OrgDb = org.Hs.eg.db,
               ont = "BP",
               pAdjustMethod = "BH",
               pvalueCutoff = 0.05,
               qvalueCutoff = 0.05, readable = TRUE)

df_gobp <- as.data.frame(ego)
gobp <- nrow(df_gobp)

gobp_table <- df_gobp[order(df_gobp$p.adjust),
                    c("Description", "GeneRatio", "p.adjust", "Count")]
knitr::kable(head(gobp_table, 10), row.names = FALSE)

dotplot(ego, showCategory=9, font.size=8)

res_de_IE <- res_DE[res_DE$DE == "Infraexpressat", ]
res_IE_entrez <- res_de_IE$entrez

```

```

egoIE <- enrichGO(
  gene           = res_IE_entrez,
  universe       = univers_entrez,
  keyType       = "ENTREZID",
  OrgDb         = org.Hs.eg.db,
  ont           = "BP",
  pAdjustMethod = "BH",
  pvalueCutoff  = 0.05,
  qvalueCutoff  = 0.05,
  readable      = TRUE)

df_gobpIE <- as.data.frame(egoIE)
gobpIE <- nrow(df_gobpIE)

gobp_tableIE <- df_gobpIE[order(df_gobpIE$p.adjust),
                          c("Description", "GeneRatio", "p.adjust", "Count")]

# es canvia el nom de la descripció perquè és molt llarg
gobp_tableIE$Description[
  gobp_tableIE$Description == "adaptive immune response based on somatic
  recombination of immune receptors built from immunoglobulin superfamily domains"
] <- "adaptive immune response based on recombination of Ig dom immune receptors"

knitr::kable(head(gobp_tableIE, 10), row.names = FALSE)

dotplot(egoIE, showCategory=9, font.size=7)

```